

第 1 讲：机器学习在学什么？

从函数拟合到物理约束学习

@ Frano

• FranSpace

本讲摘要 / Why it matters

机器学习的核心不是“让计算机变聪明”，而是通过一个带参数的模型去学习输入和输出之间的映射关系。

普通监督学习主要依赖数据标签；PINN 则进一步把控制方程、边界条件和初始条件等物理约束也写进损失函数中。因此，从机器学习过渡到 PINN，最重要的变化是：

只依赖数据 $\longrightarrow$ 同时依赖数据和物理方程.

1.1 从一个映射关系开始

机器学习最基本的问题可以理解为：

$$\mathbf{x} \mapsto \mathbf{y}.$$

这里：

- $\mathbf{x}$ 表示输入；
- $\mathbf{y}$ 表示输出；
- 模型的任务是学习从 $\mathbf{x}$ 到 $\mathbf{y}$ 的映射关系。

例如，在图像识别问题中：

图片 $\mapsto$ 类别.

在房价预测问题中：

房屋面积、位置、楼层等信息 $\mapsto$ 房价.

在固体力学 PINN 问题中, 如果用神经网络预测位移场, 则可以写成:

$$\mathbf{X} \mapsto \mathbf{u}(\mathbf{X}),$$

其中:

- $\mathbf{X}$ 是参考构形中的空间坐标;
- $\mathbf{u}(\mathbf{X})$ 是该点的位移;
- 神经网络用于近似未知位移场。

也就是说, 在 PINN 中, 神经网络可以看成是一个函数近似器:

$$\mathbf{u}_\theta(\mathbf{X}) \approx \mathbf{u}(\mathbf{X}),$$

其中 θ 表示神经网络中的全部可训练参数。

分析 / Insight

从这个角度看, 神经网络并不是神秘的东西。它本质上就是一个非常灵活的参数化函数。训练神经网络, 就是不断调整参数 θ , 使得这个函数越来越接近我们想要的目标函数。

1.2 模型、参数和超参数

为了学习映射关系, 我们需要先选定一个模型。模型可以理解为一个带参数的函数:

$$\hat{\mathbf{y}} = f_\theta(\mathbf{x}).$$

其中:

- $\mathbf{x}$ 是输入;
- $\hat{\mathbf{y}}$ 是模型预测值;
- θ 是模型参数;
- f_θ 是由参数 θ 决定的函数。

在神经网络中，参数通常包括：

$$\theta = \{W^{(1)}, b^{(1)}, W^{(2)}, b^{(2)}, \dots\}.$$

其中：

- $W^{(l)}$ 是第 l 层的权重矩阵；
- $b^{(l)}$ 是第 l 层的偏置向量。

这些参数是在训练过程中自动更新的。

• 1.2.1 模型参数

模型参数是网络自己通过训练学到的量。例如：

$$z = wx + b.$$

这里的 w 和 b 就是模型参数。

训练之前，它们通常被随机初始化；训练过程中，它们会根据损失函数的梯度不断更新。

• 1.2.2 超参数

超参数是训练开始之前人为设定的量，例如：

- 学习率；
- 网络层数；
- 每层神经元个数；
- batch size；
- epoch 数量；
- 优化器类型；
- loss 权重。

这些量一般不会通过反向传播自动学习，而是需要人为选择或通过实验调整。

备注 / Note

初学时容易混淆“参数”和“超参数”。

简单区分方法是：

训练过程中自动更新的是参数，训练前人为设定的是超参数。

例如，神经网络中的 w, b 是参数；学习率、网络深度、batch size 是超参数。

1.3 损失函数为什么重要

模型给出预测值以后，我们需要知道预测得好不好。这个“好不好”需要用一个函数来衡量，这个函数就是损失函数。

对于监督学习，如果真实值是 $\mathbf{y}$ ，预测值是 $\hat{\mathbf{y}}$ ，常见的均方误差为：

$$L = \frac{1}{N} \sum_{i=1}^N \|\hat{\mathbf{y}}_i - \mathbf{y}_i\|^2.$$

损失函数越小，说明预测值和真实值越接近。

因此，训练神经网络的目标可以写成一个优化问题：

$$\min_{\theta} L(\theta).$$

也就是说：

训练神经网络 = 寻找一组参数 θ ，使损失函数尽量小。

Example / 例子

假设只有一个简单模型：

$$\hat{y} = wx + b.$$

如果真实数据满足 $y \approx 2x + 1$ ，那么训练的目标就是让模型逐渐学到：

$$w \approx 2, \quad b \approx 1.$$

损失函数的作用就是告诉模型当前的 w, b 离理想值还有多远。

1.4 普通监督学习

普通监督学习依赖一组带标签的数据：

$$\{(\mathbf{x}_i, \mathbf{y}_i)\}_{i=1}^N.$$

训练过程可以概括为：

- 输入 $\mathbf{x}_i$ ；
- 神经网络输出预测值 $\hat{\mathbf{y}}_i$ ；
- 用损失函数比较 $\hat{\mathbf{y}}_i$ 和 $\mathbf{y}_i$ ；
- 通过反向传播计算损失对参数的梯度；
- 使用优化器更新参数；
- 重复很多次，直到模型预测较准确。

这个过程可以简写为：

$$\mathbf{x} \xrightarrow{f_\theta} \hat{\mathbf{y}} \xrightarrow{L} \text{误差} \xrightarrow{\text{反向传播}} \nabla_\theta L \xrightarrow{\text{优化器}} \theta \text{更新}.$$

分析 / Insight

普通监督学习的核心信息来自数据标签。

如果标签很多且质量很好，监督学习可以取得很好的效果。但在很多科学计算和工程问题中，高质量标签数据可能很难获得，例如需要大量有限元仿真或实验测量。

1.5 从监督学习到 PINN

PINN 的全称是 Physics-Informed Neural Network，即物理信息神经网络。

它的核心思想是：

不只让网络拟合数据，还要求网络满足物理方程。

在普通监督学习中，损失函数通常是：

$$L_{\text{data}} = \frac{1}{N} \sum_{i=1}^N \|\mathbf{u}_\theta(\mathbf{X}_i) - \mathbf{u}_i\|^2.$$

其中 $\mathbf{u}_i$ 是已知数据标签。

而在 PINN 中，即使没有很多标签数据，也可以利用控制方程构造损失。

例如，对于静力固体力学问题，参考构形下的平衡方程可以写成：

$$\text{Div } \mathbf{P} + \mathbf{B} = \mathbf{0}.$$

其中：

- $\mathbf{P}$ 是第一类 Piola–Kirchhoff 应力；

- $\mathbf{B}$ 是体力;
- $\text{Div } \mathbf{P}$ 表示对应应力场求散度。

如果神经网络预测位移场:

$$\mathbf{u}_\theta(\mathbf{X}),$$

就可以通过自动微分计算变形梯度、应力以及平衡方程残差。

于是 PDE 残差损失可以写成:

$$L_{\text{pde}} = \frac{1}{N_r} \sum_{i=1}^{N_r} \|\text{Div } \mathbf{P}_\theta(\mathbf{X}_i) + \mathbf{B}(\mathbf{X}_i)\|^2.$$

边界条件也可以写进损失函数。

例如 Dirichlet 位移边界:

$$\mathbf{u} = \bar{\mathbf{u}} \quad \text{on } \Gamma_D,$$

对应损失:

$$L_D = \frac{1}{N_D} \sum_{i=1}^{N_D} \|\mathbf{u}_\theta(\mathbf{X}_i) - \bar{\mathbf{u}}(\mathbf{X}_i)\|^2.$$

Neumann 力边界:

$$\mathbf{P}\mathbf{N} = \bar{\mathbf{T}} \quad \text{on } \Gamma_N,$$

对应损失:

$$L_N = \frac{1}{N_N} \sum_{i=1}^{N_N} \|\mathbf{P}_\theta(\mathbf{X}_i)\mathbf{N}(\mathbf{X}_i) - \bar{\mathbf{T}}(\mathbf{X}_i)\|^2.$$

因此, PINN 的总损失通常写成:

$$L = \lambda_r L_{\text{pde}} + \lambda_D L_D + \lambda_N L_N + \lambda_{\text{data}} L_{\text{data}}.$$

其中:

- L_{pde} 约束控制方程;
- L_D 约束位移边界;
- L_N 约束力边界;
- L_{data} 约束已有观测数据;
- $\lambda_r, \lambda_D, \lambda_N, \lambda_{\text{data}}$ 是不同损失项的权重。

本讲摘要 / Why it matters

普通神经网络主要通过数据告诉模型“答案是什么”。

PINN 则进一步告诉模型：

你的答案不仅要接近数据，还必须满足物理方程和边界条件。

因此，PINN 的训练目标不是单一的数据拟合，而是多个物理约束共同作用下的优化问题。

1.6 普通机器学习和 PINN 的区别

普通监督学习和 PINN 的区别可以总结为：

对比项	普通监督学习	PINN
主要信息来源	数据标签	数据 + 物理方程
输入	样本特征	空间/时间坐标等
输出	标签预测值	物理场变量
损失函数	数据误差	PDE 残差 + 边界残差 + 数据误差
核心难点	泛化能力	loss 平衡、自动微分、边界约束、采样策略

对于固体力学 PINN 来说，网络的预测结果不能只看位移是否大致正确，还需要检查：

- 平衡方程残差是否足够小；
- Dirichlet 边界是否满足；
- Neumann 边界是否满足；
- 应力结果是否与有限元结果一致；
- 角点和界面区域是否出现局部大误差；
- 不同 loss 项是否存在尺度不平衡。

备注 / Note

PINN 中一个非常重要的经验是：

总 loss 下降 $\neq$ 物理结果一定正确。

尤其在固体力学问题中，位移趋势看起来正确，并不代表应力场也正确。因为应力通常依赖位移梯度，甚至依赖非线性本构关系，对误差更加敏感。

1.7 一页总结

- 机器学习的基本目标是学习一个映射关系：

$$\mathbf{x} \mapsto \mathbf{y}.$$

- 神经网络可以看成是一个带参数的函数：

$$\hat{\mathbf{y}} = f_{\theta}(\mathbf{x}).$$

- 训练神经网络就是寻找一组参数 θ ，使损失函数最小：

$$\min_{\theta} L(\theta).$$

- 普通监督学习主要依赖数据标签，通过数据误差训练模型。
- PINN 不只利用数据，还把控制方程、边界条件和初始条件写进损失函数。
- 对固体力学 PINN，常见损失包括 PDE 残差、Dirichlet 边界损失、Neumann 边界损失和数据损失。
- PINN 中不能只看总 loss，还要分别检查位移、应力、残差、边界条件和误差云图。
- 从普通神经网络过渡到 PINN，最关键的变化是：

从数据拟合问题 $\longrightarrow$ 物理约束优化问题.