

第 5 讲：参数与超参数

哪些是模型自己学的，哪些是人为设定的

@ Frano

● FranSpace

本讲摘要 / Why it matters

神经网络训练中有两类重要的量：

模型参数 和 超参数。

模型参数是在训练过程中通过反向传播和优化器自动更新的量，例如权重 w 和偏置 b 。

超参数是在训练前人为设定的量，例如学习率、网络层数、隐藏层节点数、batch size、epoch 数和 loss 权重。

5.1 为什么要区分参数和超参数

初学神经网络时，容易把所有“可以调的量”都叫参数。

但严格来说，训练过程中有两类不同的量：

- 一类是模型自己通过训练学到的；
- 一类是训练前由人设定的。

前者叫模型参数，后者叫超参数。区分它们很重要，因为它决定了：

- 哪些量由反向传播更新；
- 哪些量需要人为调节；
- 训练失败时应该检查什么；
- 模型表达能力和训练稳定性如何控制。

5.2 模型参数

模型参数是网络内部真正被训练的量。

以最简单的线性模型为例：

$$\hat{y} = wx + b.$$

这里：

- w 是权重；
- b 是偏置；
- w 和 b 都是模型参数。

训练的目标是找到合适的 w 和 b ，使预测值 $\hat{y}$ 尽量接近真实值 y 。

损失函数可以写成：

$$L(w, b) = \frac{1}{N} \sum_{i=1}^N (wx_i + b - y_i)^2.$$

训练过程就是求解：

$$\min_{w, b} L(w, b).$$

分析 / Insight

模型参数是优化问题中的未知量。

反向传播计算的是损失函数对这些参数的梯度，例如：

$$\frac{\partial L}{\partial w}, \quad \frac{\partial L}{\partial b}.$$

5.3 神经网络中的参数

对于多层神经网络，第 l 层通常写成：

$$\mathbf{z}^{(l)} = \mathbf{W}^{(l)} \mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}.$$

其中：

- $\mathbf{W}^{(l)}$ 是第 l 层的权重矩阵；
- $\mathbf{b}^{(l)}$ 是第 l 层的偏置向量；
- $\mathbf{a}^{(l-1)}$ 是上一层输出；
- $\mathbf{z}^{(l)}$ 是当前层线性组合结果。

整个网络的参数可以记为：

$$\theta = \left\{ \mathbf{W}^{(1)}, \mathbf{b}^{(1)}, \mathbf{W}^{(2)}, \mathbf{b}^{(2)}, \dots, \mathbf{W}^{(L)}, \mathbf{b}^{(L)} \right\}.$$

训练神经网络就是求：

$$\min_{\theta} L(\theta).$$

5.4 参数如何更新

每次训练时，模型先通过前向传播计算预测结果，再计算损失函数。

然后反向传播计算：

$$\nabla_{\theta} L.$$

优化器根据梯度更新参数。例如最基本的梯度下降为：

$$\theta_{k+1} = \theta_k - \eta \nabla_{\theta} L(\theta_k).$$

其中 η 是学习率。

备注 / Note

反向传播不会直接更新参数。

反向传播负责计算梯度；优化器负责根据梯度更新参数。

5.5 超参数

超参数是训练前人为设定的量，它们不会通过普通反向传播自动学习。

常见超参数包括：

- 学习率；
- batch size；
- epoch 数；
- 网络层数；
- 每层神经元个数；
- 激活函数；
- 优化器类型；
- 权重初始化方式；

- 正则化系数;
- loss 权重;
- 采样点数量;
- 自适应采样频率。

这些量会显著影响训练效果。

5.6 几个重要超参数

• 5.6.1 学习率

学习率控制每次参数更新的步长:

$$\theta_{k+1} = \theta_k - \eta \nabla_{\theta} L.$$

若学习率过大, 训练可能震荡甚至发散; 若学习率过小, 训练可能非常慢。

• 5.6.2 网络深度和宽度

网络深度是隐藏层数量, 网络宽度是每层神经元数量。

增加深度和宽度通常可以提高模型表达能力, 但也会增加:

- 参数数量;
- 显存消耗;
- 训练难度;
- 过拟合风险;
- 自动微分成本。

• 5.6.3 batch size

batch size 控制一次用多少样本估计梯度。

较小 batch size 梯度噪声更大, 但显存占用小; 较大 batch size 梯度更稳定, 但显存占用大。

• 5.6.4 loss 权重

在 PINN 中, 总损失通常由多个部分组成:

$$L = \lambda_r L_r + \lambda_D L_D + \lambda_N L_N + \lambda_{\text{data}} L_{\text{data}}.$$

其中 $\lambda_r, \lambda_D, \lambda_N, \lambda_{\text{data}}$ 是超参数。

它们决定不同物理约束项在训练中的相对重要性。

分析 / Insight

对 PINN 来说, loss 权重是非常重要的超参数。

如果 PDE 残差项权重过大, 模型可能忽略边界条件; 如果边界项权重过大, 模型可能边界满足较好, 但内部平衡方程残差较大。

5.7 参数和超参数的区别

可以用下面的表格总结:

类型	例子	是否自动训练
参数	$w, b, \mathbf{W}^{(l)}, \mathbf{b}^{(l)}$	是
超参数	η , 层数, batch size, λ_r	否

更直观地说:

参数是模型学到的, 超参数是人先设定的。

5.8 PINN 中的特殊超参数

PINN 中的超参数比普通监督学习更多。常见包括:

- 内部残差点数量 N_r ;
- Dirichlet 边界点数量 N_D ;
- Neumann 边界点数量 N_N ;
- PDE loss 权重 λ_r ;
- 边界 loss 权重 λ_D, λ_N ;
- 网络深度和宽度;
- 激活函数;
- Adam 训练轮数;
- L-BFGS 最大迭代次数;
- 自适应采样间隔;
- 界面附近加密点数量。

对于固体力学 PINN, 还需要特别关注:

- 位移边界是否硬约束；
- 力边界 loss 权重是否足够；
- 应力误差是否被监控；
- 角点是否需要额外处理；
- 相场界面附近是否加密采样。

备注 / Note

当 PINN 结果不对时，不要只怀疑网络层数不够。
还需要检查：

- 控制方程是否写对；
- 边界条件是否一致；
- loss 权重是否平衡；
- 采样点是否覆盖关键区域；
- 自动微分是否断图；
- 本构应力是否计算正确。

5.9 一页总结

- 模型参数是训练过程中自动更新的量，例如权重和偏置。
- 超参数是训练前人为设定的量，例如学习率、batch size、网络层数和 loss 权重。
- 神经网络训练本质上是求解：

$$\min_{\theta} L(\theta).$$

- 反向传播计算损失对参数的梯度，优化器根据梯度更新参数。
- 学习率、网络深度、网络宽度和 batch size 都会影响训练效果。
- PINN 中的超参数还包括残差点数量、边界点数量、loss 权重和自适应采样策略。
- 对固体力学 PINN，调超参数之前应先确认物理方程、边界条件和本构实现正确。