

第 8 讲: 前向传播

理解神经网络如何从输入生成输出

@ Frano

● FranSpace

本讲摘要 / Why it matters

前向传播 (Forward Propagation, FP) 是神经网络 (Neural Network, NN) 从输入到输出的核心计算过程。每一层神经元 (Neuron, NN) 将输入信号加权整合、加偏置，再经过激活函数 (Activation Function, AF) 输出。前向传播不仅生成预测结果，也为反向传播和梯度计算奠定基础。在 PINN 中，前向传播输出是 PDE 残差、边界条件和初始条件损失计算的基础。

8.1 前向传播的基本概念与特征抽象

在神经网络中，每个神经元的输出可以看作输入特征的某种抽象表示。设输入向量为 $\mathbf{x} = [x_1, x_2, \dots, x_n]^T$ ，第 l 层权重矩阵为 $\mathbf{W}^{(l)}$ ，偏置为 $\mathbf{b}^{(l)}$ ，激活函数为 σ ，则第 l 层输出为：

$$\mathbf{a}^{(l)} = \sigma(\mathbf{W}^{(l)}\mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}), \quad \mathbf{a}^{(0)} = \mathbf{x}.$$

- 第一隐藏层：捕捉原始输入的线性组合特征；
- 中间层：通过非线性激活提取高阶特征组合；
- 输出层：将抽象特征映射为目标输出。

分析 / Insight

每层输出都可以理解为“对输入特征的逐层抽象”，前向传播体现了网络逐层提取和重构信息的能力。

8.2 批处理前向传播与矩阵形式

在实际训练中，通常一次输入多个样本形成 batch $\mathbf{X} \in \mathbb{R}^{N \times d}$ ，前向传播公式为：

$$\mathbf{A}^{(l)} = \sigma(\mathbf{A}^{(l-1)} \mathbf{W}^{(l)T} + \mathbf{b}^{(l)}),$$

其中 N 为 batch 大小， d 为输入维度。批处理有助于计算效率和梯度估计稳定性。

Example / 例子

假设输入 batch 为 $N = 32$ 个二维坐标 (X, Y) ，每个样本经过三层隐藏层 MLP，最终输出位移 (u, v) ，通过矩阵运算一次计算所有 32 个样本的预测结果。

8.3 前向传播在 PINN 中的应用

在 PINN 中，前向传播结果不仅是输出预测：

- 残差点：通过前向传播得到位移/场变量预测，用于计算 PDE 残差；
- 边界点：预测值用于计算 Dirichlet 和 Neumann 边界损失；
- 初始条件点：前向传播输出用于时间演化初值损失。

通过前向传播得到的输出，可进一步通过自动微分计算梯度：

$$\frac{\partial \mathbf{u}_\theta}{\partial \mathbf{X}}, \quad \mathbf{F} = \mathbf{I} + \nabla \mathbf{u}_\theta$$

生成 PDE 残差，并组成训练损失。


8.4 可视化与直观理解

前向传播可以类比为“信号流水线”：

- 输入层接收原始信息；
- 隐藏层经过加权、偏置和激活函数处理，逐层抽象；
- 输出层生成预测结果。

前向传播的基本流程

前向传播（Forward Propagation）是指输入数据从输入层开始，依次经过各层的线性变换与激活函数，最终得到输出的过程。



整体公式（从输入到输出）

设网络共有 L 层（不含输入层），则前向传播可按层递推表示为：

$$\begin{cases} a^{(0)} = x \\ z^{(l)} = W^{(l)} a^{(l-1)} + b^{(l)}, \quad l = 1, 2, \dots, L \\ a^{(l)} = \sigma(z^{(l)}), \quad l = 1, 2, \dots, L \end{cases} \quad \hat{y} = a^{(L)}$$

其中， $a^{(l)}$ 为第 l 层的激活（输出）， $z^{(l)}$ 为第 l 层的线性变换结果， $\hat{y}$ 为最终输出。

符号说明

符号	含义	说明
x	输入向量	$x \in \mathbb{R}^{n_0}$ ，第 0 层激活： $a^{(0)} = x$
$W^{(l)}$	第 l 层权重矩阵	$W^{(l)} \in \mathbb{R}^{n_l \times n_{l-1}}$
$b^{(l)}$	第 l 层偏置向量	$b^{(l)} \in \mathbb{R}^{n_l}$
$z^{(l)}$	第 l 层线性变换结果	$z^{(l)} \in \mathbb{R}^{n_l}$ ， $z^{(l)} = W^{(l)} a^{(l-1)} + b^{(l)}$
$\sigma(\cdot)$	激活函数	如 ReLU, sigmoid, tanh 等
$a^{(l)}$	第 l 层激活（输出）	$a^{(l)} = \sigma(z^{(l)}) \in \mathbb{R}^{n_l}$
$\hat{y}$	最终输出	$\hat{y} = a^{(L)} \in \mathbb{R}^{n_L}$
n_l	第 l 层的神经元个数	n_0 为输入维度， n_L 为输出维度

图 1: MLP 前向传播示意图：输入层 (IL)、隐藏层 (HL)、输出层 (OL)

8.5 前向传播与网络容量

- 深度 (Depth): 隐藏层数量越多，特征抽象能力越强；
- 宽度 (Width): 每层神经元数量越多，特征表达空间越大；
- 高容量网络生成的前向特征更丰富，但训练计算成本更高。

8.6 二维位移场 PINN 示例

输入 (X, Y) ，输出位移 (u, v) ：

- 第一隐藏层: $\mathbf{a}^{(1)} = \sigma(\mathbf{W}^{(1)} \mathbf{x} + \mathbf{b}^{(1)})$;
- 第二隐藏层: $\mathbf{a}^{(2)} = \sigma(\mathbf{W}^{(2)} \mathbf{a}^{(1)} + \mathbf{b}^{(2)})$;
- 输出层: $\hat{\mathbf{u}} = \mathbf{W}^{(3)} \mathbf{a}^{(2)} + \mathbf{b}^{(3)}$ 。

Example / 例子

每个残差点 (X_i, Y_i) 前向传播得到预测位移，用于计算 PDE 残差和边界条件损失。




图 2: MLP 前向传播示意图: 输入层 (IL)、隐藏层 (HL)、输出层 (OL)

8.7 前向传播的注意事项

- 输入维度、归一化必须与训练时一致;
- 激活函数选择影响输出连续性及梯度质量;
- 输出必须精确, 以保证 PDE 残差和边界损失计算正确;
- 多输出任务应选择适当输出层激活函数, 如 Linear 或 Softmax。

8.8 一页总结

- 前向传播 (Forward Propagation, FP) 是神经网络生成输出的核心过程;
- 每层输出经过线性变换和激活函数 (AF) 作为下一层输入;
- 批处理和矩阵形式可提高计算效率;

- 在 PINN 中，前向传播结果用于 PDE 残差、边界和初始条件损失计算；
- 信号逐层抽象，反映网络容量和非线性表达能力；
- 可视化有助于理解信息传递与特征抽象；
- 前向传播正确性直接影响训练稳定性和物理场预测精度。