

第 12 讲: 学习率

控制参数更新步长的关键超参数

@ Frano

● FranSpace

本讲摘要 / Why it matters

学习率 (Learning Rate, LR) 是神经网络训练中最重要的超参数之一。它控制每一次参数更新的步长: 学习率太小, 模型训练会非常慢; 学习率太大, loss 可能震荡甚至发散。对普通神经网络来说, 学习率影响收敛速度和训练稳定性; 对 PINN 来说, 学习率还会影响 PDE 残差、边界条件损失和数据损失之间的训练平衡。理解学习率, 是理解梯度下降、Adam、学习率调度以及 Adam + L-BFGS 两阶段训练策略的基础。

12.1 学习率在参数更新中的位置

在上一讲中, 我们已经介绍了梯度下降的基本公式:

$$\theta_{k+1} = \theta_k - \eta \nabla_{\theta} L(\theta_k).$$

其中 θ_k 表示第 k 次迭代时的参数, $\nabla_{\theta} L(\theta_k)$ 表示当前参数处的梯度, η 就是学习率。

从这个公式可以看出, 梯度决定更新方向, 学习率决定沿这个方向走多远。若梯度是“方向盘”, 学习率就是“油门”。方向正确但油门太小, 移动很慢; 方向正确但油门太大, 也可能直接冲过目标点。

分析 / Insight

学习率并不改变梯度方向, 但会改变参数更新的步长。它看似只是一个系数, 却会直接决定训练是稳定下降、缓慢前进, 还是剧烈震荡。

12.2 从一维函数理解学习率

假设损失函数只有一个参数：


$$L = L(\theta).$$

在当前位置 θ_k ，梯度下降更新为

$$\theta_{k+1} = \theta_k - \eta \frac{dL}{d\theta}.$$

若学习率很小，那么即使梯度较大，每次参数移动距离也很短；若学习率较大，参数移动距离就会变长。问题在于，损失函数通常不是一条简单直线，而是弯曲的曲线。如果步子迈得太大，就可能越过低损失区域。

学习率决定沿负梯度方向走多远



图中从同一个起点出发，不同学习率对应不同更新距离。学习率过小时，只向低损失方向移动了一小段；学习率合适时，可以较快接近低谷；学习率过大时，可能直接跨过低谷，甚至移动到更差的位置。

12.3 学习率过小会发生什么

学习率过小时，最直接的问题是训练速度慢。每次参数只更新一点点，即使方向是对的，也需要很多次迭代才能明显降低 loss。

在训练曲线上，学习率过小通常表现为：

- loss 下降非常慢;
- 训练很长时间后仍然没有明显改善;
- 参数更新幅度很小;
- 误差云图变化不明显;
- 在有限训练时间内表现得像“没有学会”。

但需要注意, 学习率过小不等于模型一定错误。它可能只是还没有训练足够久。不过在实际研究中, 训练时间有限, 如果学习率太小, 模型就很难在可接受时间内收敛到较好结果。

Example / 例子

假设当前梯度为

$$\nabla_{\theta} L = 10.$$

如果学习率为 $\eta = 10^{-6}$, 则一次更新量只有

$$\eta \nabla_{\theta} L = 10^{-5}.$$

即使方向正确, 参数每一步也几乎没有明显变化。这时 loss 曲线可能看起来非常平。

12.4 学习率过大会发生什么

学习率过大时, 参数更新步长过长, 可能导致训练不稳定。即使负梯度方向在当前位置是下降方向, 如果一步走得太远, 也可能越过低谷, 进入损失更大的区域。

在训练曲线上, 学习率过大通常表现为:

- loss 大幅震荡;
- loss 偶尔下降, 但很快又上升;
- 出现 NaN 或 Inf;
- 参数数值变得很大;
- PINN 中应力或 PDE 残差出现异常尖峰。

备注 / Note

训练过程中如果 loss 突然变成 NaN，不一定是网络结构本身错误，也可能是学习率过大导致参数更新过猛，进而让某些中间量溢出。

12.5 学习率和 loss 曲线的关系

观察 loss 曲线是判断学习率是否合适的重要方式。一般来说，可以从以下现象初步判断：

- loss 平稳下降：学习率大概率比较合适；
- loss 几乎不变：学习率可能太小，也可能梯度为 0 或计算图有问题；
- loss 剧烈上下震荡：学习率可能偏大；
- loss 先下降后发散：学习率可能在训练后期偏大；
- 总 loss 下降但某些子 loss 不下降：PINN 中可能存在 loss 权重或采样问题。

对普通监督学习，观察训练 loss 和验证 loss 已经能发现很多问题；但对 PINN，必须进一步分别观察每个子 loss，例如 PDE loss、Dirichlet loss、Neumann loss 和 data loss。

12.6 固定学习率

最简单的设置方式是固定学习率，即整个训练过程中 η 保持不变：

$$\eta_k = \eta_0.$$

固定学习率的优点是简单、易于理解、容易复现实验。缺点是很难同时兼顾训练前期和后期。训练前期可能需要较大学习率快速下降；训练后期则可能需要较小学习率精细收敛。

例如，前期使用较大学习率可以快速把参数带到合理区域，但后期若仍保持较大学习率，可能在最优点附近震荡；反过来，若一开始就使用很小学习率，前期下降又会很慢。


12.7 学习率调度

学习率调度 (Learning Rate Schedule) 指训练过程中动态改变学习率，而不是一直使用固定值。常见策略包括：

- 阶梯衰减：每隔一定 epoch 将学习率乘以一个衰减系数；
- 指数衰减：学习率按照指数规律逐渐减小；

- 余弦退火：学习率按照余弦曲线逐渐下降；
- ReduceLROnPlateau：当 loss 长时间不下降时降低学习率；
- warmup：训练初期先从小学习率逐渐升高。

常见学习率调度曲线



学习率调度的核心思想是：训练的不同阶段需要不同步长。前期需要快速探索，后期需要精细调整。

12.8 warmup 的作用

warmup 是指训练刚开始时不直接使用目标学习率，而是先从较小值逐步增加到目标值。这在大型网络或训练初期梯度不稳定时很有用。

直观上，模型刚初始化时参数比较随机，输出和梯度可能不稳定。如果一开始就使用较大学习率，参数可能被推到很差的位置。warmup 相当于让模型先“热身”，等梯度逐渐稳定后再加快训练。

虽然普通 PINN 入门算例中不一定必须使用 warmup，但在复杂问题中，特别是损失项很多、尺度差异较大时，warmup 可以提高训练稳定性。

12.9 学习率与 batch size 的关系

batch size 会影响梯度噪声。小 batch 梯度噪声更大，大 batch 梯度更稳定。因此，学习率和 batch size 往往需要一起考虑。

一般来说：

- batch size 较小时，梯度噪声较大，学习率过大容易震荡；
- batch size 较大时，梯度更稳定，可以尝试稍大的学习率；
- full-batch 训练中，梯度更确定，但每次更新成本较高。

在 PINN 中，batch size 的含义还会更复杂。因为训练点可能包括内部残差点、边界点、初始条件点和数据点。不同点集的数量和比例都会影响梯度方向，从而影响学习率选择。

12.10 学习率与优化器的关系

不同优化器对学习率的敏感程度不同。普通梯度下降直接使用

$$\theta_{k+1} = \theta_k - \eta \nabla_{\theta} L.$$

因此它对学习率非常敏感。学习率稍微不合适，训练就可能很慢或震荡。

Adam 则会根据历史梯度的一阶矩和二阶矩调整每个参数的实际更新幅度。它仍然需要学习率，但这个学习率可以理解为整体步长尺度。相比普通梯度下降，Adam 通常更容易训练深度神经网络。

L-BFGS 则不同。它是拟牛顿方法，会利用历史梯度和参数变化估计曲率信息，并常常结合线搜索确定步长。因此在使用 L-BFGS 时，学习率概念不像 Adam 那么直接，但仍然会有步长控制和线搜索相关参数。

备注 / Note

在 PINN 中常见的 Adam + L-BFGS 策略可以理解为：先用 Adam 在较大学习率下快速找到较好区域，再用 L-BFGS 进行更精细的收敛。

12.11 PINN 中学习率为什么更敏感

PINN 中学习率往往比普通监督学习更敏感，原因有几个：

- 总损失由多个物理约束项组成，尺度可能差别很大；
- PDE 残差可能包含高阶导数，对参数变化更敏感；
- 应力由位移梯度或能量导数得到，误差容易被放大；
- 边界条件和内部残差可能存在训练竞争；

- 不同采样点分布会改变梯度方向。

因此，在 PINN 中不能只看总 loss 是否下降。学习率看似合适时，也可能只是在优化某一部分 loss，而其他物理约束没有得到充分训练。

12.12 如何为 PINN 选择学习率

对初学者来说，可以从比较保守的策略开始：

- Adam 阶段先尝试 10^{-3} ；
- 若 loss 剧烈震荡，可以尝试 10^{-4} ；
- 若 loss 下降太慢，可以在确认公式无误后尝试稍微增大；
- 训练时分别记录各个子 loss；
- 在后期可逐渐降低学习率；
- Adam 收敛到一定程度后再切换 L-BFGS。

对于你当前的固体力学 PINN 问题，还需要特别关注 Neumann 边界和应力误差。如果学习率过大，应力场很容易出现不合理震荡；如果学习率过小，力边界条件可能长期训练不充分。

12.13 学习率调试流程

实际调试中，可以按下面的顺序检查：

1. 先确认控制方程、边界条件和自动微分实现没有明显错误；
2. 用一个中等学习率训练，例如 Adam 的 10^{-3} ；
3. 观察总 loss 和各子 loss 的下降趋势；
4. 若 loss 发散或震荡，减小学习率；
5. 若 loss 长时间几乎不变，检查梯度是否为 0 或学习率是否过小；
6. 若总 loss 下降但某些子 loss 不下降，优先检查 loss 权重和采样点；
7. 后期根据收敛情况使用学习率衰减或切换 L-BFGS。

这个流程的重点是：不要把所有训练问题都归因于学习率。学习率很重要，但它不能修复错误的 PDE、错误的边界条件或错误的本构关系。

12.14 常见误区

关于学习率，初学者常见误区包括：

- 误区一：学习率越大，训练越快。
学习率过大会导致震荡或发散，并不一定更快。
- 误区二：学习率越小，训练越稳定。
学习率太小虽然不容易爆炸，但可能训练非常慢，甚至看起来完全没有进展。
- 误区三：只要调学习率，就能解决所有训练问题。
如果 loss 公式、边界条件或自动微分写错，调学习率无法从根本上解决问题。
- 误区四：总 loss 下降说明学习率合适。
对 PINN 来说，还要检查每个子 loss 和关键物理量误差。
- 误区五：Adam 的学习率和 L-BFGS 的步长可以完全等同理解。
Adam 有显式学习率，L-BFGS 通常结合曲率估计和线搜索，二者的步长机制不同。

12.15 一页总结

- 学习率 (Learning Rate, LR) 控制每次参数更新的步长。
- 梯度决定更新方向，学习率决定沿这个方向走多远。
- 学习率过小会导致训练很慢，学习率过大可能导致震荡、发散、NaN 或 Inf。
- 固定学习率简单，但不一定适合训练全过程；学习率调度可以让前期快速下降、后期精细收敛。
- 学习率需要和 batch size、优化器、loss 权重以及问题尺度一起考虑。
- 在 PINN 中，学习率不仅影响总 loss，也影响 PDE 残差、边界条件和数据项之间的训练平衡。
- 对初学者来说，Adam 阶段可以先尝试 10^{-3} 或 10^{-4} ，再根据 loss 曲线和物理误差调整。
- 学习率很重要，但它不能代替对控制方程、边界条件、本构关系和自动微分实现的检查。